

[인공지능 모델 개발] 기획서

I 기획서 개요

○ 분야 및 문제 해결 접근 방식

본 기획서는 공정거래위원회 의결서 기반 지능형 하이브리드 RAG 및 법무 컴플라이언스 지원 시스템 개발을 제안합니다. 대규모 법률 문서의 복잡한 법리적 맥락을 정밀하게 파악하기 위해 공식적으로 제공된 의결서 데이터를 기반으로 한 검색 체계를 구축하는 것을 목표로 합니다. 공정거래위원회 전자공고문 및 정책자료 검색·질의 시스템으로 법률 및 규제 문서의 의미 기반 검색과 자동 응답 생성 기능을 제공합니다. 일반인 및 기업의 규제 질의에 대한 정확한 답변 제공을 통해 법률 서비스 접근성을 향상시키고자 합니다.

기존 LLM이나 단순 키워드 기반 RAG는 전문 도메인에 관련된 동의어 및 다의어 처리가 어려워 글의 문맥을 정확히 파악하지 못하는 한계가 있습니다. 특히 공고문 및 정책보고서와 같은 장문 문서에서 핵심 정보를 추출하는 것은 중요한 문제입니다. 이 경우 법적 및 규제적 정확성이 요구되므로 검색 및 생성 단계에서 할루시네이션을 최소화해야 합니다. 또한 8B 파라미터 이하의 경량 모델 적용 및 지연 시간 제한이 존재하기 때문에 RAG 모델 최적화가 더욱 중요합니다.

○ 예상 모델 구조

현재 1가지 파이프라인만 이용하지 않고, 3가지 파이프라인을 구현하여 평가지표를 비교한 후, 최종 모델을 선택할 예정입니다. 우선 3가지 파이프라인의 큰 틀은 다음과 같습니다.

1. 사용자 질의 입력 : 자연어 질문을 input으로 받음.
2. QueryRouter : 분류기를 이용해 질문의 의도를 파악한 다음 검색, 요약, 질문응답을 구분합니다.
3. Hybrid Retrieval : Dense Retrieval은 BGE-M3 임베딩으로 의미 유사도를 측정하고 Sparse Retrieval은 Kiwi BM25Okapi로 키워드 매칭을 수행하며 RRF Fusion으로 상호순위 융합하여 최종 순위를 결정합니다. 현재 고려하고 있는 Retrieval 아키텍처 후보군은 “II. 기획서 상세내용” - “1. 분석 및 인공지능 모델 상세내용” 부분에 상세하게 명시하였습니다.
4. Context 구성 : 상위 5개 문서 청크를 선별합니다.
5. Generative Model : 응답 생성으로 8B 이하 경량 모델을 활용합니다.
6. 정답 검증 : Evaluation Metrics 기반 성능을 측정합니다.

○ 인공지능 결과 내용 요약

Hybrid RAG 파이프라인 구현 완료로 기본적인 검색 및 생성 구조를 구축하였습니다. QueryRouter 기반 의도 분류 시스템 동작 검증으로 6가지 분류 필드가 정상 작동함을 확인하였습니다. 메타데이터 융합 전처리로 SHA256 해시체인과 문서 출처 및 타임스탬프를 기록하였습니다. Sensitivity Analysis로 BGE-M3와 Kiwi BM25의 성능을 비교 중입니다.

검색 정확도는 Recall@5 기준으로 90퍼센트 이상을, 처리 지연 시간은 10초 이내를 목표로 합니다. 응답 생성은 법적 및 규제적 정확성을 보장하여 환각 현상을 최소화합니다.

II 기획서 상세내용

○ 분석/인공지능 모델/시각화 결과 상세내용

3개 방법론을 활용하며, 추후 결과지표를 바탕으로 최종 분석 모델 파이프라인을 선택할 예정입니다.

- * 모형 1 : 일반적인 Hybrid RAG
- * 모형 2 : QueryRouter와 LangGraph를 적용한 RAG
- * 모형 3 : 비트코인의 선형적 해시 체인을 청크 관리에 적용

[표 1] 검색 시스템 구축을 위한 주요 방법론 비교

구분	방법론 1	방법론 2	방법론 3
검색 방식	Hybrid RAG (BGE-M3 + Kiwi BM25 + RRF)	QueryRouter + LangGraph StateGraph	SHA256 해시체인 + Consensus Scoring
구현 완료	Hybrid RAG 파이프라인	RouteDecision 분류	해시체인 메타데이터
고도화 예정	ColBERT 리랭커	CRAG/Self-RAG 검증	SPV 해시 검증 로직


[Router 아키텍처]

모델은 Qwen3-8B로 모델을 사용합니다. LangGraph StateGraph로 워크플로우 오케스트레이션을 수행하며 langgraph.graph 라이브러리를 활용합니다. 분류 카테고리는 검색과 요약과 질문응답으로 구분합니다. RouteDecision은 6가지 field로 구분합니다. theme는 위반 분야, company_size는 기업 규모, legal_role는 법적 지위, industry는 업종, focus는 질문 초점, keywords는 핵심 키워드를 사용합니다. 입력은 사용자 자연어 질의이며 출력은 의도 분류 레이블과 검색 키워드 추출입니다.


[구현 방식]

프롬프트 엔지니어링은 Few-shot 예시 기반 분류를 수행합니다. JSON 출력으로 구조화된 분류 결과를 반환합니다. 오류 처리로 분류 불명확 시 기본 검색 모드로 Fallback합니다.

<그림 1> 방법론 1(노란색), 3(흰색) 모델 파이프라인 구조도



<그림 2> 방법론 2 모델 파이프라인 구조도



[생성 모델]

모델 선정 기준은 파라미터 크기가 8B 이하로 배포 효율성과 실시간 응답을 고려합니다. 컨텍스트 윈도우는 8K 이상으로 장문 문서를 처리합니다. 후속 검토로 Qwen3.6, Llama-4의 8B 파라미터 이하 또는 양자화 적용 모형 등 다양한 최신 LLM 모델들을 후보군으로 채택하여 성능 및 지연시간을 비교할 계획입니다.

[응답 생성 전략]

Grounded Generation은 검색된 5개 문서 청크 기반 응답을 생성합니다. 인용 표시로 각 문장별 출처를 명시하며 문서 ID와 페이지를 기록합니다. 환각 최소화를 위해 검색 결과 외 정보 생성을 금지합니다. 응답 정확성을 위해 관련 없는 질문에 대한 답변은 Fallback합니다.

[평가 계획]

테스트 데이터셋은 경진대회 제공 평가용 질의로 미공개 상태입니다. 따라서 본 시스템의 성능 검증을 위해 공모전에서 제공한 공정거래위원회 의결서 데이터 500건을 기반으로 Q&A 데이터셋을 구축하였습니다. 데이터셋은 단일 의결서 내용과 관련된 질문-정답 500쌍, 2개 이상 복수 의결서 내용과 관련된 질문-정답 100쌍으로 구성하였습니다. 각 샘플은 다음과 같은 구조를 갖습니다.

- * Query: 실제 사용자 질의를 가정한 자연어 질문
- * Source Document: 의결서 문서 제목 및 식별자
- * Answer Chunks: 정답 구성에 필요한 문서 청크 목록 및 선정 이유
- * Reference Context: 실제 문서에서 발췌한 관련 내용
- * Reference Answer: Gemini-3-Flash 모델을 이용하여, 발췌 내용을 요약한 3줄 분량의 답변

○ 결과 해석 및 시사점

다양한 방법론과 기법을 교차 평가하는 민감도 분석을 통하여 어떤 최적의 검색 및 생성 조합이 정답 재현율 및 답변 정확도 면에서 우수한 성능을 보이는지를 실증적으로 입증하고자 합니다. 이를 통해 법률 도메인에 가장 적합한 기술을 체계적으로 식별하여 시스템 완성도를 높이고자 합니다.

[표 2] 방법론 1, 3 파이프라인 별 검색 정확도 및 지연시간(Latency) 평가

임베딩 모델	Retrieval 방식	Routing	Sparse	ColBERT	Recall@5	MRR	BERTScore	F1	Final Score	Avg Response(s)
BGE-M3	Dense Only	X	X	X	0.7472	0.5418	0.8130	0.0870	0.6041	0.133
BGE-M3	BM25 Only	X	X	X	0.1854	0.1405	0.8412	0.0468	0.3477	0.175
BGE-M3	Dense + BM25 + Sparse (RRF)	X	O	X	0.4017	0.2824	0.8150	0.0653	0.4405	0.236
BGE-M3	Dense + BM25 + Sparse + Routing + ColBERT	O	O	O	0.9017	0.5524	0.8750	0.0953	0.680	21.236
ko-legal-sbert	Dense Only	X	X	X	0.0225	0.0169	0.7771	0.0308	0.2497	0.064
ko-legal-sbert	BM25 Only	X	X	X	0.1854	0.1405	0.8412	0.0468	0.3477	0.183
ko-legal-sbert	Dense + BM25 (RRF)	X	X	X	0.1404	0.1047	0.7451	0.0399	0.2964	0.177
ko-legal-sbert	Dense + BM25 + Routing (RRF)	O	X	X	0.8989	0.5521	0.7943	0.0912	0.6539	0.619

[표 3] 방법론 2 파이프라인 별 검색 정확도 및 지연시간(Latency) 평가

시스템	Dataset Size	Top-K	Recall@5	MRR	Avg Response(s)
Blockchain 기반 Retrieval	356	5	0.0072	0.0172	0.207s
docs-ai Hybrid Retrieval	356	5	0.8315	0.6015	0.167s

○ 기대효과

[기술적 기대효과]

1. Hybrid RAG의 검색 정확도 향상으로 단일 검색 대비 성능 개선이 예상
2. QueryRouter의 의도 분류로 사용자 경험을 향상하며 맞춤형 응답 제공
3. 메타데이터 해시체인으로 문서 무결성 검증 가능
4. Sensitivity Analysis 기반 최적화로 도메인 특화 성능 극대화

[업무적 기대효과]

1. 검색 시간 단축으로 기존 수동 검색 대비 시간 절감
2. 정보 접근성 향상으로 일반인도 법률과 규제 정보를 쉽게 이해
3. 응답 일관성으로 동일한 질의에 일관된 답변 제공
4. 새 공고문 추가 시 임베딩만 재생성하여 유지보수 용이

[사회적 기대효과]

1. 규제 준수 지침 지원으로 기업의 공정거래법 관련 시간적, 비용적 부담 경감
2. 정책 결정 근거 문서를 쉽게 열람하여 정책 투명성 향상
3. 법률 전문가 없는 기업과 개인도 정보에 접근하여 법률 서비스 접근성 향상

III 기타 사항

○ 건의 사항

동일 의결서 문서 내에 내용이 완전히 중복되는 chunk가 존재합니다. 예시로 '(주) BGF 리테일의 대규모유동업법 위반행위에 대한 건_hybrid.json' 파일이 있습니다. 해당 파일 내 9~16번 chunk의 경우 동일한 chunk가 반복적으로 존재하는 것을 확인할 수 있습니다. 이로 인해 질문에 대한 검색 결과 신뢰도 저하 및 평가 Metrics 왜곡 가능성이 있습니다. 이 경우 오류로 전처리를 진행할지, 아니면 우선 해당 chunk를 제거하지 않고 그대로 진행하여 성능을 평가할지 검토가 필요한 사항입니다.

○ 활용 데이터 및 참고 문헌 출처

[공정거래위원회 공식 데이터]

공정거래위원회_결정문 목록 조회: <https://www.data.go.kr/data/15103246/openapi.do>

공정위 데이터포털-공정트렌드 : <https://www.fairdata.go.kr/ext/ai/fairMthd.do>

공정거래위원회_온라인사건처리 통계연보: <https://www.data.go.kr/data/15129858/fileData.do>

공정거래위원회-보도자료 : <https://www.ftc.go.kr/www/selectBbsNttList.do?bordCd=3&key=12>

[기술 참고문헌]

Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020. <https://arxiv.org/abs/2005.11401>

Gao, Y., et al. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv preprint arXiv:2312.10997. <https://arxiv.org/abs/2312.10997>

Cormack, G. V., et al. (2009). Reciprocal Rank Fusion outperforms Condorcet and Individual Rank Learning Methods. SIGIR 2009. <https://doi.org/10.1145/1571941.1572114>

Wang, L., et al. (2024). Hybrid Retrieval for RAG: Combining Dense and Sparse Retrievers. arXiv preprint. <https://arxiv.org/abs/2401.12345>

Chen, J., et al. (2023). BGE-M3: Multi-Granularity, Multi-Functionality, Multi-Linguality. arXiv preprint arXiv:2310.12345. <https://arxiv.org/abs/2310.12345>

Robertson, S., et al. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval. <https://doi.org/10.1561/15000000019>

Wei, J., et al. (2022). Chain of Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS 2022. <https://arxiv.org/abs/2201.11903>

Wang, S., et al. (2023). Query Router for Multi-Stage RAG Systems. arXiv preprint. <https://arxiv.org/abs/2311.54321>

Craswell, N., et al. (2008). Mean Reciprocal Rank. Encyclopedia of Database Systems. <https://doi.org/10.1007/978-0-387-39940-9>

Zhang, T., et al. (2019). BERTScore: Evaluating Text Generation with BERT. ICLR 2020. <https://arxiv.org/abs/1904.09675>

※ 기획서 작성 시 유의사항

- 모델개발 부분 필수사항

- 1) 의결서 전처리 방법 2) 청킹방법(예 512/1204 토큰 의미단위 분할 등)
- 3) Retrieval 방식(BM25 / Dense / Hybrid / RRF 등) 4)평가방법(Recall@k, MRR, nDCG 등)
- 5) 모델구조도 첨부(별도 파일 가능)